具有模糊边界的医学图像的结构边界保持分割

摘要

针对医学图像中存在的两个关键问题: (1) 在医学图像中医学解剖结构的边界具有模糊性 (2) 在没有专业领域知识的情况下分割区域的不确定性,本文提出了一种新的图像分割方法。针对解剖结构边界模糊问题,本文提出了一种新的结构边界保持分割框架。为了实现结构边界保持,设计了边界关键点选取算法。该算法能够找出目标物体的结构边界上的关键点,然后引入边界保持块 (BPB) 以及与边界关键点的映射,实现对目标对象结构边界的预测。此外,为了在全自动分割中嵌入专家知识,提出了一种新的形状边界感知评估器 (SBE) 与专家标注的 ground-truth 结构信息。所提出的 SBE 可以根据结构边界关键点对分割网络进行给予反馈。所提出的方法具有足够的通用性和灵活性,可以构建在任何基于深度学习的分割网络之上。本文验证了该方法的有效性,并提高了三种不同的分割网络模型对不同类型的医学图像数据集进行分割任务的准确性。同时,本次复现没有可参考代码,凭借对论文的理解尝试复现,并在实验中做出如下改动:通过 Prewitt 算子提取真实值的边缘生成边缘掩膜图。生成的边缘掩膜图用于实现对目标物体的结构边界预测。它使分割网络能够进一步利用目标对象的边缘结构。然后,为了得到更好的分割结果,使用边缘保持网络会产生的不确定性熵图和网络预测值,聚焦模型关注区域,为下阶段模型消除背景干扰。得到了不错的实验结果。

关键词: 医学图像分割; 关键点选取; 形状感知

1 引言

对于许多医学图像处理应用,模型在医学图像域中正确分割解剖结构是成功的重要关键 [9] [4]。然而,由于结构边界的模糊性、纹理的不均匀性以及分割区域的不确定性,在没有领域知识的情况下,获得准确的分割结果具有挑战性。即使是专家也会根据他们的经验和技能在他们的描绘上略有不同 [5]。

在深度学习时代,已经提出了许多基于卷积神经网络(CNN)的分割方法,以在自然和医学图像域中准确地分割目标对象。全卷积网络(FCN)[3] 具有跳过层以保留空间定位信息,用于语义分割。受 FCN 的启发,提出了 U-Net [7],用于利用更高层的上下文信息,通过将更高分辨率的特征与上采样的特征相结合来预测精确的输出。Zhao 等人 [14] 将 FCN 和条件随机场集成在统一的分割框架中,用于脑肿瘤分割。这些基于深度学习的医学图像分割方法没有明确考虑到医学图像中的困难,例如模糊的结构边界和异质纹理。显示了 U-Net 无法分割超声图像中目标区域的情况。为了处理模糊的结构边界问题,已有的一些方法 [13] [1]。这些方法强制像素间依赖性以恢复边界细节。然而,它们需要手动参数调整作为后处理,这是劳

动密集型任务,并且结果受到参数调整的影响。为了克服这个限制,已经提出了交互式或半自动分割方法,其中在测试时间期间交互式地处理模糊的结构边界。交互式分割方法将用户输入(如点,边界框)应用于分割网络。Wang 等人 [12]。提出了一种基于深度学习的医学图像领域交互式分割方法。他们动编码目标对象的结构边界信息; 网络可以预测复杂的结构。然而,交互方法需要用户交互时间和专门的领域知识。本文主要研究医学图像领域提出的两个分割问题。首先,大多数应用中的医学图像包含模糊的边界,因为图像质量差,纹理不均匀。与自然图像中的对象不同,由于低分辨率,可能没有显著的结构边界。其次,在没有专家知识的情况下,很难自动预测正确的目标区域,例如超声图像中的黑色素细胞病变。

为了解决上述问题,我们提出了一种新的全自动医学图像分割框架,保持目标区域的结构边界。首先,我们提出了一种新的边界关键点选择算法。该算法自动选择最适合目标对象区域的关键点。这些点放在目标物体的结构边界上。然后,使用一种新的结构边界保持模型(Boundary Preserving Block, BPB)将点编码到分割网络中。它允许分割模型进一步利用结构边界信息。在所提出的 BPB 中,边界关键点地图是从视觉特征估计的。为了在全自动分割模型中嵌入专家知识,我们引入了一种新的基于结构边界信息的判别网络,命名为形状边界感知评估器(SBE),以对抗的方式,无需用户交互。在训练阶段,它试图评估有多少结构边界的分割图是很好地保存使用的关键点地图。因此,建议的 SBE 可以给予反馈的分割网络上的预测区域,根据专家标记的地面实况区域。此外,上述方法具有通用性和灵活性,适用于任何自动医学图像分割模型。所提出的方法的灵活性,允许任何分割模型,以更精确地分割目标区域,结合 BPB 和 SBE。

2 相关工作

近年来,深卷积神经网络 (DCNN) 在自然图像和医学图像领域都取得了巨大的成功。全卷积网络 (FCN) [3] 是自然图像和医学图像上应用最广泛的分割网络之一 FCN 由一系列连续的卷积层和最大池化层构成。为了保留更多的空间定位信息,引入了跳跃连接层。许多医学图像分割网络使用模糊神经网络进行医学图像分割。Roth 等人 [8] 应用 FCN 网络级联方式进行医学图像分割。Vorontsov 等人 [11] 使用两种类型的 FCNs 进行肝脏和肝脏病变的分割。除了 FCN,U-Net 在医学图像分割中表现出了优越的性能。U-Net [7] 利用跳跃连接结构,将编码器中高级别的特征与解码器中相应的低级别特征进行连接,帮助网络更好地还原分割目标的边缘和细节,被广泛应用于医学图像分割,尤其在生物医学领域,如细胞和器官的分割任务中表现出色。受 U-Net 的启发,许多基于深度学习的自动分割网络被提出。Dalm 等人 [2] 提出了 2 个和 3 个连续 U-Net 用于乳腺肿块分割。虽然这些方法在医学图像分割中取得了合理的分割效果,但仍然存在边缘结构丢失的问题。

交互式医学图像分割通常,交互式分割显示出比传统分割方法上级的性能。在医学图像分割中,它表现出很好的性能,因为它将专家知识编码到具有多个交互的分割网络中。Rajchl等人 [6] 通过使用用户提供的输入来训练 CNN 网络。通过提供特定的区域信息,提高了分割预测性能。Wang 等人 [10] 提出了基于深度学习的交互式分割方法。他们采用结边缘信息发送到分段网络。与以前的交互方法不同,它们通过使用精细化网络来减少用户交互。这些方法通过使用用户交互显示了优越的结果。然而,他们仍然需要在推理时与专家进行交互。

3 本文方法

3.1 本文方法概述

整体分割框架由边界保持块(BPB)和形状边界感知评估器(SBE)分割网络。BPB 和 SBE 使用从我们的新的关键点选择算法中选择的边界关键点来保持目标对象的结构边界。在 BPB 中,生成关键点图并用于细化输入特征。然后,分割网络预测结构边界保持分割图。在 SBE 网络中,将给定的分割图与边界关键点图是否重合反馈给分割网络。在分割网络和 SBE 以对抗的方式训练之后,仅使用分割网络进行推理。网络结构如图 1所示。

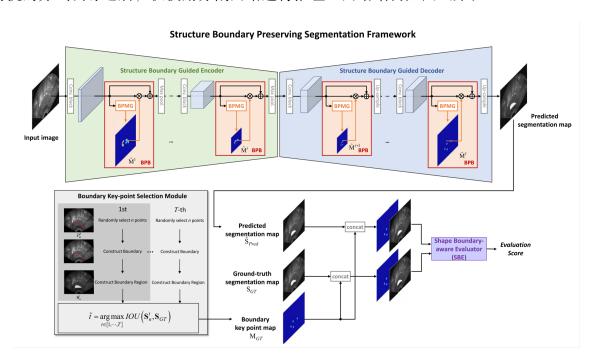


图 1. 结构边界保持分割框架

3.2 边界关键点选取算法

为了获得最适合真实分割图的边界关键点,并代表目标区域的结构边界,我们设计了一种新的边界关键点选择算法。首先,我们使用传统的边缘检测算法从真实分割图中获得目标对象的边界。在目标对象的边界上,我们随机选择 n 个点。设 $P_n^t = \{(x_1^t, y_1^t), (x_2^t, y_2^t), \cdots, (x_n^t, y_n^t)\}$ 表示随机选择的 n 个点集,其中 t 表示试验次数(即,迭代)。然后,我们通过在第 t 次迭代中连接 n 个点来构造边界区域 S_n^t 。为了获得真实值边界关键点图,我们通过计算交集超过并集(IOU)来测量边界区域 $S_n^t = c(P_n^t)$ 与真实分割图 S_{GT} 之间的重叠区域的量。c (·) 是从所选择的点集构造边界区域的函数 P_n^t 。最后,选择导致 IOU 最大值的边界点作为结构边界关键点。选定的关键点写为

$$\tilde{P} = P_n^{\tilde{t}}, where \ \tilde{t} = \arg\max_{t \in \{1, \dots, T\}} IOU\left(S_n^t, S_{GT}\right)$$
(1)

将选定的关键点集 P 转换为二维关键点图。为了提高训练时对关键点的感知准确度,在每个关键点上生成时添加一个可扩展范围。设 X 为图像中的二维关键点位置。设 $D(y)=\{x:||x-y||< R\}$ 是一个以 y 为中心的半径为 R 的圆盘。我们设置一个二元分类任务,如果

x 在 D(y) 中,则 p(x) = 1,或者 p(x) = 0。因此,我们将关键点图视为二维概率图,并使用交叉熵来训练模型。这些点图用于训练分割网络和 SBE。在本次实验中,将 y 定义为 3。

3.3 边界保持块 (BPB)

如图 2所示,具有边界保持块(BPB)的分割网络预测分割图。建议的 BPB 包括边界点地图生成器,以估计边界关键点地图。通过生成边界关键点图,分割网络编码结构边界信息而不相互作用。边界点映射生成器使用特征 $f^i \in \mathbb{R}^{w^i \times h^i \times c^i}$ 作为输入,其中 $w^i \times h^i$ 和 c^i 分别表示第 i 个卷积块处的视觉特征的宽度、高度和通道。根据输入视觉特征 f^i ,生成器生成边界关键点图,然后,生成的边缘映射图 \hat{M}_i 类似于剩余注意力方案,用于保留 f^i 的边缘信息,结构边界信息保留特征 $v^i \in \mathbb{R}^{w^i \times h^i \times c^i}$ 可以写为:

$$v^i = f^i \oplus (f^i \otimes \hat{M}^i) \tag{2}$$

其中, \oplus 和 \otimes 分别表示逐元素加法和逐通道乘法。在乘法处理中,针对每个信道号广播 \hat{M}^i 。边缘结构保留特征 v^i 被馈送到第 (i+1) 个卷积块。

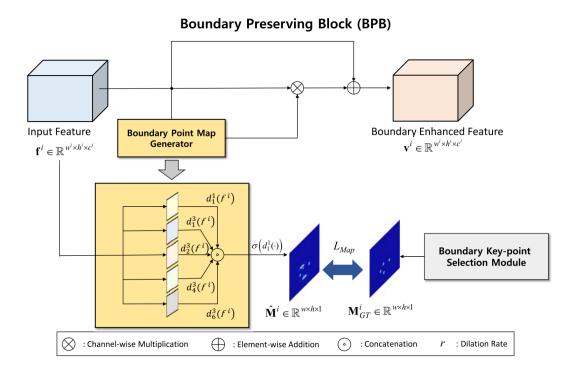


图 2. 结构边界保持分割框架

3.4 边界关键点地图生成器

图 2示出了所提出的边界关键点图生成器架构。边界关键点图生成器通过考虑各种感受野来估计边界关键点图。边界关键点图生成器中,通过采用膨胀卷积去编码/解码各种尺度的感受野的特征。设 $d_s^r(\cdot)$ 表示具有扩张率 r 和滤波器大小为 $s \times s$ 的扩张卷积函数。将具有各种感受野的编码特征 $d_s^r(f^i)$ 映射图使用通道卷积连接,并使用激活函数将其投影到边界关键点映射空间中。所生成的边缘映射 \hat{M}^i 可以被写为:

$$\hat{M}^{i} = \sigma(d_{1}^{1} \left\{ d_{1}^{1}(f^{i}), d_{1}^{3}(f^{i}), d_{2}^{3}(f^{i}), d_{4}^{3}(f^{i}), d_{6}^{3}(f^{i}) \right\})$$
(3)

其中 σ 表示 sigmoid 函数。通过最小化估计的边缘图 \hat{M}^i 和真实值边缘掩膜 \hat{M}^i_{GT} 之间的交叉熵损失来优化边缘图生成器。

3.5 形状边界感知评估器 (SBE)

为了在全自动分割模型中嵌入专家知识,提出了一种基于结构边界信息的判别网络形状边界感知评价器(SBE)。SBE 通过使用边界关键点地图向分割网络提供反馈。为此,SBE 将边界关键点图和分割图像(预测的或真实值)作为输入。边界关键点图和给定的分割图像跨通道连接并馈送到 SBE 网络中。然后,SBE 评估分割结果是否与边界关键点图一致。给定地面实况分割图 SGT 和边界关键点图,SBE 提供高评估分数。另一方面,对于预测不良的分割图和边界关键点图,SBE 提供低评估分数,因为预测不良的分割图与边界关键点图不一致。为此,我们用以下损失训练了 SBE 网络。

$$L_{SBE} = -log(D(S_{GT}; M_{GT};)) - log(1 - D(\hat{S}_{Pred}; M_{GT}))$$
(4)

3.6 损失函数定义

为了以对抗的方式训练包括所提出的 BPB 和所提出的 SBE 的分割网络,我们采用了三种类型的损失函数。第一个是分割损失函数,以减少分割真值和预测分割图之间的差异。它被定义为:

$$L_{Seg} = -SGT \cdot log(\hat{S}_{Pred}) - (1 - S_{GT}) \cdot log(1 - \hat{S}_{Pred})$$

$$\tag{5}$$

第二个是关键点图损失,其被设计用于所提出的关键点图生成。最后一个是考虑 SBE 的反向 传播的边界感知损耗。边界感知损失被设计为允许分割网络通过考虑边界关键点来实现准确 的分割结果。它可以写成:

$$L_{BA} = -log(D(\hat{S}_{Pred}; M_{GT})) \tag{6}$$

通过减少边界感知损失,分割网络预测结构边界保留的分割结果。最后,用于训练分割 网络的总损失函数可以定义为:

$$L_{Total} = L_{Seg} + L_{BA} + \sum_{i=1}^{l} L_{Map}^{i}$$

$$\tag{7}$$

其中, L 表示分割网络中的 BPB 的总数, L_{Total} 表示分割训练损失。

4 复现细节

4.1 与已有开源代码对比

本实验在进行复现时,没有任何参考任何相关源码。

在本实验中,一共完成了两部分实验,第一部分:原文网络结果复现,第二部分:在原文网络的基础上进行改进。

4.2 创新改进部分

4.2.1 由关键点保持改进为边界保持

在实际的实验过程中,我们注意到关键点选取算法的运行时间较长,并且所找到的关键点并未准确定位于模糊边界处,而更倾向于服务于扩大交并比(IOU)范围。这与我们期望在具有模糊边界的结构中找到更准确的分割目标的目标相矛盾。为了解决这一问题,我们提出了一种创新的方法,即使用完整的目标边缘结构来改进关键点选择,从而显著减少预处理数据所需的时间。

这一想法的核心在于,通过使用目标的完整边缘结构,我们能够更精准地捕捉目标在模糊边界区域的位置,而非依赖于传统的关键点选取算法。这不仅提高了分割目标的准确性,同时也使得我们能够在更短的时间内完成数据预处理。

在这个方法中,我们特别将边缘信息的损失反向传播圈定在边缘保持模块中。通过这一策略,我们实现了对边缘信息的更精细控制,使边缘保持模块能够更专注地处理边缘信息,而不受其他模块的干扰。这种设计不仅提高了边缘信息的准确性,还有助于避免因其他模块的影响而引入的噪音,从而进一步优化了整个模型的性能。

与传统方法相比,这种基于完整目标边缘结构的新方法在两个方面带来了明显的优势。首先,通过减少对关键点的依赖,我们成功地降低了预处理数据的时间成本,使整个实验过程更为高效。其次,通过将边缘信息的处理集中在边缘保持模块中,我们提高了模型对边缘信息的敏感性和精确度。

改进结构如图 3所示:

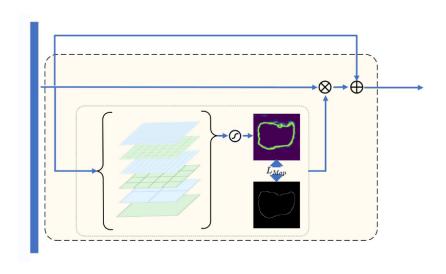


图 3. 边缘保持模块

4.2.2 由对模型形状感知评分改进为聚焦模型感知范围

原论文在提升模型对目标结构形状感知能力方面采用了模型形状感知得到的损失。然而, 该损失函数存在一些局限性,无法准确描述图像上需要关注的形状结构。为了克服这一问题, 我们提出了一系列改进措施,旨在更有效地提高模型对目标形状的感知准确性。

首先,我们通过边缘保持网络生成不确定性熵图和网络预测值来反映模型在边缘区域的 不确定性。这一改进的方法允许模型更加灵活地适应不同场景中的目标结构,并更好地理解 图像中的边缘信息。不确定性熵图提供了关于模型在特定区域的置信度信息,而网络预测值则反映了模型对目标形状的预测。这样的结合使得模型能够更有针对性地聚焦在关键区域,为下一步的模型优化提供了更精确的方向。助于消除来自背景的干扰,提高模型对目标结构的感知准确性。

具体实现过程:由第一阶段网络输出的预测概率分布图。首先通过 sigmoid 函数进行激活,设置阈值为 0.5,当概率值大于等于 0.5 时记为真值,此时得到第一阶段网络输出的第一个内容:确定肿瘤区域。其次将已经使用 sigmoid 函数激活的概率图,通过计算每个像素的熵生成不确定性图。熵越高,不确定性越大。熵的计算公式如下:

$$H(X) = -\sum_{i=1}^{n} \cdot \log_2 P(x_i) \tag{8}$$

H(X) 是像素点的 X 熵,n 是可能的状态的数量, $P(x_i)$ 是随机变量 X 取值为 x_i 的概率。设置阈值为 0.1,当熵图的概率值大于等于 0.1 时,将此像素记为下阶段模型需要注意的区域,取值为真。

将第一阶段网络得到的两个图相加,得到希望下阶段网络聚焦的区域。此时将希望关注的区域的值设为 1,将其余区域设为 0,得到对原图像的掩码模板。将掩码模板与原图像做逐元素乘法,得到的结果作为下阶段网络的输出,即希望下阶段网络不再关注背景区域。整个流程如图 4所示。

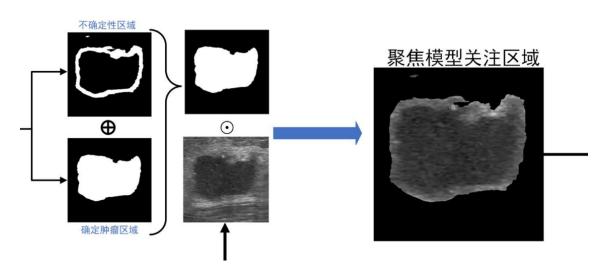


图 4. 聚焦模型感知范围,消除背景干扰

4.3 实验环境搭建

在两个医学图像分割数据集进行实验验证提出的模型。第一个是 PH2 皮肤病变挑战数据集,另一个是 breast_1k 乳腺超声数据集。PH2 数据集是一个可用于评估皮肤病变分割的公共数据集。PH2 数据集包括 200 张皮肤镜图像。将本数据集按照 7:3 的比例随机划分训练集和测试集。使用同样的模型参数,在第二个数据集进行实验。第二个数据集 breast_1k 乳腺肿瘤图像数据集。breast_1k 数据集共包括 977 张图片,将本数据集按照 5:5 的比例随机划分训练集和测试集。

实验使用随机梯度下降作为优化器对模型进行优化,在两个网络结构中学习率均为 0.001。 训练轮次均为 40 轮,使用随机初始化的权重,每个批次 2 个数据。在训练网络之前,预先创 建关键点图和真实值边缘掩膜。

5 实验结果分析

5.1 整体实验结果分析

为了证明所提出网络的优势,将本文方法分割网络与 U-Net 、和 U-NetBPB 进行比较。将我们的方法与其他方法进行了比较。至于评估指标,利用 Dice 系数和 Jaccard 系数。表 1 定量比较了在 PH2 数据集上,本文方法,U-Net 和 U-NetBPB。如表 1 所示,我们的方法在 Dice 中达到 92.12%,在 JCS 中达到 83.08%。均比 U- Net 有所提升,但是在 Jaccard 中比 U-NetBPB 模型低。Jaccard 系数得分较低具体原因还未找到。猜想方向为引入边缘的信息可能存在作用范围,并不在所有图像中都有效。总体而言,本文方法有性能上的提升。

| | Dice | Jaccard |
|------------------|-------|---------|
| U-Net | 87.89 | 79.36 |
| $U	ext{-}NetBPB$ | 90.91 | 84.08 |
| \mathbf{OURS} | 92.12 | 83.68 |

表 1. 在 PH2 数据集上比较我们的方法, U-Net 和 U-NetBPB 的 Dice 和 Jaccard 系数

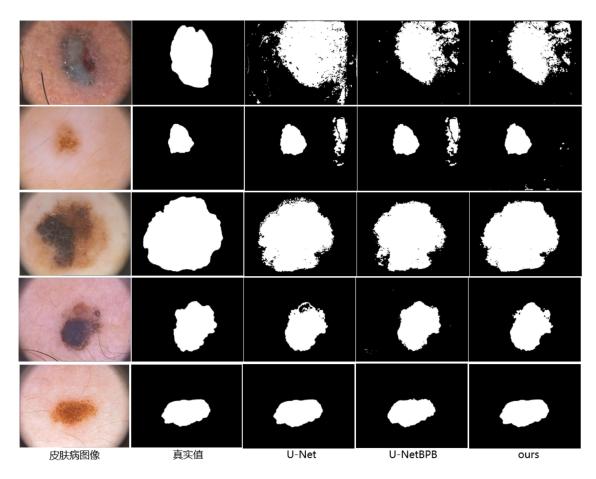


图 5. 实验结果

为了进一步评估所提出的方法,在 $breast_1k$ 进行了同样的实验。如表 2 所示,我们的方法在 DCS 和 JCS 中分别达到 86.52% 和 77.51%。与 U-Net 相比,Dice 和 Jaccard 的性能

分别提高了 4.11% 和 6.42%。由于 U-NetBPB 方法数据预处理阶段在本数据集上需要 20 天 左右,时间紧张,只在本数据集上与 U-Net 进行比较。

| | Dice | Jaccard |
|-------|-------|---------|
| U-Net | 82.11 | 71.09 |
| OURS | 86.52 | 77.51 |

表 2. 在 breast_1k 数据集上比较我们的方法和 U-Net 的 Dice 和 Jaccard 系数

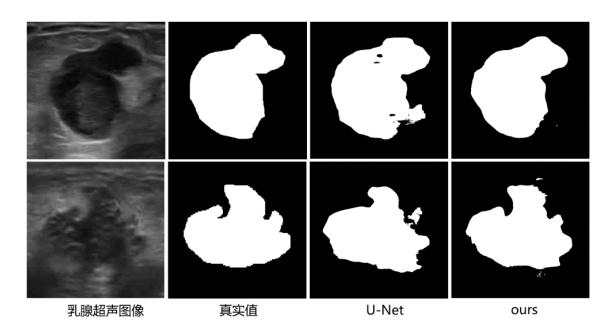


图 6. 实验结果

5.2 消融实验结果分析

为了证明所提出的两种方案都对模型的分割精度提升有贡献,将只使用一种方案的模型与 U-Net 和都使用的模型进行对比。首先,分别使用两种方案的模型对比 U-Net 都有不同程度的提升,证明两种方案都能对分割任务起到提升的作用。其次,完整的模型比分别使用两种方案的模型都要高,证明两个方案联合可以发挥出更好的效果。实验结果如表 3 所示。

| | Dice | Jaccard |
|---------------------------------|-------|---------|
| $\mathbf{U}	ext{-}\mathbf{Net}$ | 82.11 | 71.09 |
| OURS | 86.52 | 77.51 |
| OURS (只边缘结构保持) | 86.17 | 76.86 |
| OURS (只聚焦模型感知范围) | 84.97 | 75.41 |

表 3. 消融实验结果

6 总结与展望

本文提出了一种创新性的医学图像分割方案,专注于解决医学图像中存在的边缘模糊特性,以提高分割精度。本文的方法通过对网络注入边缘知识和聚焦模型关注区域的方式,聚 焦于维护目标对象结构边缘。

首先,为了捕捉医学图像中的边缘特征,使用 Prewitt 算子来提取真实值的边缘信息。Prewitt 算子是一种常用于边缘检测的卷积核,可以在图像中高效地提取水平和垂直方向的梯度信息。通过对真实值图像处理,生成了边缘掩膜图,其中包含了图像中目标对象结构的重要边缘信息。了更好地利用这些边缘信息,本文引入了边缘知识注入模块。这一模块的目的是单独学习和注入 Prewitt 算子提取的边缘知识到本文的分割网络中。通过训练这个模块,本文使得分割网络能够更加专注于目标对象的边缘结构,从而提高了分割的准确性。在边缘知识注入的基础上,本文引入了不确定性熵图的概念。这一步骤的目标是生成一个辅助图,其中包含了分割网络预测的不确定性信息。通过对网络预测值和不确定性熵图的分析,本文能够聚焦模型的关注区域,有助于下一阶段的模型在分割过程中消除背景干扰。实验结果表明,本文提出的方法在医学图像分割任务中取得了显著的性能提升。通过注入 Prewitt 算子提取的边缘信息,本文的方法成功地改善了分割网络对医学图像中目标对象结构边缘的捕捉能力,从而实现了更为精准的分割结果。

总的来说,本文的方法不仅在理论上充分考虑了医学图像的特殊性质,而且在实际应用中取得了令人满意的效果。这一研究为医学图像分割领域提供了一种创新的、有效的方法,有望在医学影像诊断等领域产生积极的影响。

参考文献

- [1] Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. *IEEE transactions on pattern analysis and machine intelligence*, 40(4):834–848, 2017.
- [2] Mehmet Ufuk Dalmış, Geert Litjens, Katharina Holland, Arnaud Setio, Ritse Mann, Nico Karssemeijer, and Albert Gubern-Mérida. Using deep learning to segment breast and fibroglandular tissue in mri volumes. *Medical physics*, 44(2):533–546, 2017.
- [3] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3431–3440, 2015.
- [4] Dong Nie, Li Wang, Lei Xiang, Sihang Zhou, Ehsan Adeli, and Dinggang Shen. Difficulty-aware attention network with confidence learning for medical image segmentation. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 33, pages 1085–1092, 2019.

- [5] Hyenok Park, Hong Joo Lee, Hak Gu Kim, Yong Man Ro, Dongkuk Shin, Sa Ra Lee, Sung Hoon Kim, and Mikyung Kong. Endometrium segmentation on transvaginal ultrasound image using key-point discriminator. *Medical physics*, 46(9):3974–3984, 2019.
- [6] Martin Rajchl, Matthew CH Lee, Ozan Oktay, Konstantinos Kamnitsas, Jonathan Passerat-Palmbach, Wenjia Bai, Mellisa Damodaram, Mary A Rutherford, Joseph V Hajnal, Bernhard Kainz, et al. Deepcut: Object segmentation from bounding box annotations using convolutional neural networks. *IEEE transactions on medical imaging*, 36(2):674–683, 2016.
- [7] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention-MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18*, pages 234–241. Springer, 2015.
- [8] Holger R Roth, Hirohisa Oda, Xiangrong Zhou, Natsuki Shimizu, Ying Yang, Yuichiro Hayashi, Masahiro Oda, Michitaka Fujiwara, Kazunari Misawa, and Kensaku Mori. An application of cascaded 3d fully convolutional networks for medical image segmentation. Computerized Medical Imaging and Graphics, 66:90–99, 2018.
- [9] Berkman Sahiner, Aria Pezeshk, Lubomir M Hadjiiski, Xiaosong Wang, Karen Drukker, Kenny H Cha, Ronald M Summers, and Maryellen L Giger. Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1):e1–e36, 2019.
- [10] Ran Shi, King Ngi Ngan, Songnan Li, and Hongliang Li. Interactive object segmentation in two phases. *Signal Processing: Image Communication*, 65:107–114, 2018.
- [11] Eugene Vorontsov, An Tang, Chris Pal, and Samuel Kadoury. Liver lesion segmentation informed by joint liver segmentation. In 2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018), pages 1332–1335. IEEE, 2018.
- [12] Guotai Wang, Maria A Zuluaga, Wenqi Li, Rosalind Pratt, Premal A Patel, Michael Aertsen, Tom Doel, Anna L David, Jan Deprest, Sébastien Ourselin, et al. Deepigeos: a deep interactive geodesic framework for medical image segmentation. *IEEE transactions on pattern analysis and machine intelligence*, 41(7):1559–1572, 2018.
- [13] Tao Wang, Jian Yang, Zexuan Ji, and Quansen Sun. Probabilistic diffusion for interactive image segmentation. *IEEE Transactions on Image Processing*, 28(1):330–342, 2018.
- [14] Yuyin Zhou, Lingxi Xie, Wei Shen, Yan Wang, Elliot K Fishman, and Alan L Yuille. A fixed-point model for pancreas segmentation in abdominal ct scans. In *International conference on medical image computing and computer-assisted intervention*, pages 693–701. Springer, 2017.